

# Report progetto DSS Lab

Matteo Di Giorgio 582207

## Struttura schema DW:

Rispetto allo schema proposto nella consegna lo schema realizzato mostra diverse differenze.


La più importante è l'introduzione della tabella vendors, tenere il venditore come attributo delle tabelle Ram, Cpu e Gpu, causava la duplicazione dei dati per ogni venditore distinto per uno stesso prodotto.

Inoltre sono stati aggiunti attributi alla tabella time che si possono rivelare utili per l'analisi dei dati.

L'attributo month si riferisce a un mese di uno specifico anno, mentre month\_of\_year è il valore numerico scollegato dall'anno, similamente month\_name è la stringa del nome del mese.

Invece dell'attributo day sono stati inseriti l'attributo date, che rappresenta la data completa, è day\_of\_month, ossia il valore numerico del giorno del mese

Un altro cambiamento riguarda la tabella Gpu, per cui non era disponibili l'attributo gpu\_series, ma invece nei dati era presente l'attributo gpu\_processor, che è stato inserito nello schema



## Popolamento del database:

Quasi tutti i dati richiesti erano reperibili o facilmente ottenibili dai file csv forniti, gli unici dati più complessi da ottenere erano i dati relativi alle vendite in dollari.

Date le fluttuazioni del tasso di cambio era opportuno calcolare il cambio dalla valuta della vendita ai dollari utilizzando il tasso di cambio al momento della vendita, tuttavia il piano gratuito dell'API utilizzata per ottenere i tassi di cambio permetteva solo 100 richieste al mese, rendendo impossibile ottenere il tasso per ogni giorno, sono state provate altre API ma queste non supportavano la richiesta di dati storici pur permettendo più richieste.

Data la limitazione i cambi di valuta di tutte le vendite in un dato mese usano i tassi di cambio relativi al 1° di quel mese.

Per il suo corretto funzionamento, il file "Extract and Transform.py" necessita che i file di origine dati "computer\_sales.csv" e "geography.csv" siano nella sua stessa cartella, in quanto accede ai file tramite file path.

L'esecuzione del main del file "Extract and Transform.py" genererà, all'interno della cartella in cui si trova, dei file csv contenenti i dati che il main del file "Load.py" caricherà nel database, come nel caso precedente, accedendo ai dati tramite file path è necessario che "Load.py" sia nella stessa cartella in cui vengono generati i dati, ossia la stessa in cui si trova "Extract and Transform.py".

## Processo ETL:

Il workflow ETL ha 7 componenti, i primi 4 generano le view necessarie per ottenere i risultati dell'analisi richiesta, nello specifico:

- Computer Sales Time Geography join : crea la view derivata dal join di Computer\_Sales, Time e Geography
- Rank Cpu by sales: crea una view in cui per ogni regione, anno e cpu, viene calcolato il ranking delle cpu in base alle vendite
- Compute total sales by CPU series: crea una view in cui per ogni cpu\_series viene calcolato il totale delle vendite
- Computers with 1st ranked CPUs: facendo il join tra le prime due view generate (su cpu\_id, year e region), e filtrando per i rank = 1, genera la view contenente per ogni regione e anno i sale\_id dei computer che montavano la cpu più venduta dell'anno in quella regione

Il componente di flusso seguente è un'attività di flusso di dati, che facendo gli opportuni join, e calcolando la percentuale che le vendite totali dei PC che montano le CPU più vendute per regione e anno rappresentano rispetto al totale delle vendite di tutti i PC che montano una CPU della stessa serie, ottiene i risultati dell'analisi richiesta e li salva in dei file csv.

I due componenti successivi sono delle attività esegui processo che fanno visualizzare dal notepad i file dei risultati.

Il processo include 3 variabili che servono a selezionare il percorso file in cui salvare i file csv, per il corretto funzionamento del programma la variabile "ProjectFolderPath" va impostata con il path in cui si desidera salvare i file.

Se eseguito su un dispositivo che non ha notepad installato va cambiato l'eseguibile a cui le attività esegui processo passano i percorsi dei file prodotti con un eseguibile di un'app in grado di aprire file csv.

## Data cube:

Per il data cube come misure sono state usate solo quella del conteggio e quelle inerenti alle vendite totali, di Ram, Cpu e Gpu in dollari, essendo le uniche misure sempre aggregabili, dato che sommare le vendite espresse in valute diverse non avrebbe alcun significato.

Le dimensioni coincidono con ognuna delle dimension tables, l'unico caso particolare è la tabella Vendors, che essendo collegata alla tabella Computer Sales da 3 foreign key genera 3 dimensioni distinte: per i venditori di Ram, di Cpu, e di Gpu.

Per quanto riguarda le gerarchie, ne sono state definite 5:

- **Cpu :**

| Gerarchia       | Gerarchia 1     |
|-----------------|-----------------|
| ▪ Cpu Brand     | ▪ Cpu Brand     |
| •• Cpu Name     | •• Cpu Series   |
| <nuovo livello> | <nuovo livello> |

- **Gpu:**

| Gerarchia                    |
|------------------------------|
| ▪ Gpu Processor Manufacturer |
| •• Gpu Processor             |
| <nuovo livello>              |

- **Geography:**

| Gerarchia       |
|-----------------|
| ▪ Continent     |
| •• Country      |
| ••• Region      |
| <nuovo livello> |

- **Time:**

| Gerarchia       |
|-----------------|
| ▪ Year          |
| •• Month        |
| ••• Date        |
| <nuovo livello> |

Per quanto riguarda le dipendenze funzionali, oltre quelle tra chiave e attributi, è quelle legate alle gerarchie, sono state definite:

- Region → Currency
- Date → Day Of Month
- Date → Day Of Week
- Date → Week
- Month → Quarter
- Month Name → Month Of Year

Per quanto sarebbe sarebbe sembrato logico, non è stato possibile definire una gerarchia tra il nome delle Ram e il loro brand, in quanto era presente un'eccezione che falsificava la dipendenza funzionale parent-child per la Ram "Galax Hof" che è il nome di una Ram di 2 brand diversi (non del tutto vero, il secondo brand è solo una collaborazione tra il primo e un altro).

In una situazione che includeva un committente questo avrebbe comportato contattare lo stesso per decidere come gestire dati di questo tipo, la soluzione più semplice sarebbe stata quella di alterare il nome della Ram per questo caso.

Un caso simile è incorso nella definizione della gerarchia delle Cpu. La gerarchia delle Cpu avrebbe dovuto avere la forma name-series-brand, tuttavia in nome di Cpu "AMD Sempron 3850" compare in 2 serie diverse, invalidando la dipendenza funzionale.

La soluzione è stata quella di spezzare la gerarchia in name-brand, e series-brand. Come nel caso precedente questo sarebbe stato un caso da sottoporre al committente per discuterne la gestione, una possibile soluzione sarebbe stata quella di creare un parametro name\_series derivato dalla concatenazione del nome della Cpu e dalla sua serie da usare nella gerarchia.

## Query MDX:

La query fa quanto richiesto, restituendo una tabella con sulle colonne i top 5 brand per vendite medie mensili, e sulle righe le varie regioni d'europa.


Per la query vengono definite le misure per la media mensile per Ram, Cpu e Gpu, e le misure per ottenere i top 5 per per media mensile, le misure non sono aggregabili per giorno.

Sono state inoltre realizzate inoltre 3 ulteriori query distinte, per Ram, Cpu e Gpu per visualizzare le medie mensili e i totali delle vendite dei top 5 brand per ogni regione d'Europa.

## Dashboard:

Con l'utilizzo di Power Bi sono state realizzate 2 dashboard con 2 grafici l'una.

- **Differenza count e total sales:**




In questa prima dashboard è possibile confrontare per mese e paese, il conteggio delle vendite con il loro totale in dollari.

Tra i vari risultati evidenziabili si può notare come per gli Stati Uniti sembra che con meno dollari si acquistino più computer, per determinare se questo sia vero andrebbe prima visto se invece semplicemente negli Stati Uniti ci sia la tendenza ad acquistare componenti meno costose.

Sempre per gli Stati Uniti è interessante notare come intorno alla fine del 2016 ci sia stato un pesante calo delle vendite, da cui c'è stata una forte risalita in termine di dollari nei mesi successivi, ma non altrettanto pesante a livello di numero di vendite, questo potrebbe suggerire che per far fronte al calo delle vendite dovuto a cause sconosciute, i negozi abbiano alzato i prezzi. Chiaramente questo risultato andrebbe indagato più a fondo prima di trarre conclusioni.

Da notare inoltre come poco dopo gli USA anche Australia, Canada e Nuova Zelanda abbiano riscontrato un calo nelle vendite. Si potrebbe indagare se questi cali siano correlati tra loro, e a quello negli USA poco precedente.

- **Outlayer RAM:**



Indagando su quale fosse il brand di RAM con più vendite per mese si è evidenziato un outlayer, tuttavia, con una discrepanza tale dagli altri dati, per non parlare di come questo dato non si veda sui total sales, si può dedurre che si tratti di un errore.

Andrebbe indagato su quale sia la RAM con un valore RAM Sales scorretto, è corretto nel modo più opportuno, correggendo il record se possibile o rimuovendolo altrimenti